EcoPrune：基于熵引导敏感性的非线性稀疏映射用于LLM剪枝

匿名作者[1]

摘要

权重剪枝是大型语言模型（LLMs）的有效压缩技术。然而，现有方法如PrunerGPT、OWL和DLP采用不准确的敏感性估计和僵化的线性稀疏度分配，导致性能欠佳。本文提出EcoPrune——一种基于熵引导的两阶段剪枝框架，实现稳健的权重级非线性稀疏度分配。在预剪枝阶段，EcoPrune通过最小化归一化重要性分数的熵值，学习正交变换以集中参数重要性，从而在不改变模型输出的情况下获得便于剪枝的参数化。在剪枝阶段，我们基于转换后的权重计算熵敏感性度量，并引入两种非线性稀疏度分配策略：(i)带高斯调整的范围约束方案，（ii）基于Sigmoid映射的无约束概率方案。EcoPrune具有模型无关性，可无缝集成到现有剪枝框架中。实验在LLaMA-3和Qwen-2上进行。5/3在困惑度和零样本准确率方面表现出持续改进，在70%稀疏比下，绝对准确率最高可提高**5%**，推理速度提升**1.5倍**。

1. 引言

剪枝（Jaiswal等人，2023；Ma等人，2023；Sun等人，2023；Muralidharan等人，2024；Cai等人，2024；Men等人，2025）是一种有效的压缩技术，可减少参数并提升大型语言模型（LLMs）的推理效率（Achiam等人，2023；Touvron等人，2023；Dubey等人，2024；Guo等人，2025；Qwen等人，2025；Yang等人，2025）。近期方法（Frantar & Alistarh，2023；张等人、2024；孙等人、2023；顾等人、2025提出了改进的剪枝准则和基于Transformer的LLMs重构策略，能够在适当校准下实现显著稀疏性且退化有限。

然而，这些方法大多仍采用跨层统一的稀疏率，忽略了不同层（及层内矩阵）对模型质量的贡献度不均，这往往导致高稀疏度时出现显著性能下降。现有非均匀稀疏分配方法可根据粒度进行分类。**层级**方法为每个Transformer层分配单一稀疏率。OWL（Yin等人，2024）和DLP（Chen等人，2025）通过离群值统计或权重/激活衍生指标评估层重要性，并对次要层进行更激进的剪枝。虽然有效，但层级分配是粗粒度的，无法区分同一层内矩阵的异质角色（例如注意力和MLP投影）。**权重级**方法按权重矩阵分配稀疏度。PrunerGPT（Shao等人，2024）通过海森矩阵迹估计权重级分数，并将排序矩阵映射到固定稀疏区间[$R-\alpha$，$R+\alpha$]。这种更精细的粒度提高了灵活性，但面临两个实际限制：(i)分数依赖于海森矩阵迹估计，计算量大且对稳定化选择敏感；（ii）其分配本质上是刚性的线性秩到稀疏度规则，在重尾或聚类分数分布下可能次优。

为解决这些问题，我们提出基于重要性**集中度**的**熵**引导非线性稀疏映射方法（EcoPrune），该两阶段框架在剪枝前重塑参数重要性，从而实现熵引导的非线性稀疏分配。具体而言，EcoPrune包含以下组成部分：

第一阶段：预剪枝重要性集中。受DenoiseRotator（Gu等人，2025）的启发，EcoPrune训练器通过学习正交变换来最小化归一化重要性分数的熵，从而将重要性集中到更小的参数子集中，同时通过Transformer的不变性保持模型功能。

第二阶段：基于熵的敏感性与权重级非线性稀疏分配剪枝。阶段后

[1]匿名机构、匿名城市、匿名地区、匿名国家。通信联系人：匿名作者<anon.email@domain.com>。

初步研究。正在接受国际机器学习会议（ICML）评审。请勿传播。

ICML 2026审稿人：在审阅本文时，请遵循审稿人控制台上指定的LLM使用政策。请注意，分配的LLM政策可能与您在审稿人注册时指定的政策不同。

1，EcoPrune 利用所得熵值指导真实剪枝（Frantar & Alistarh，2023；Dong 等，2024；基于熵值的权重层级稀疏度分配策略：较低的熵值表明重要性分布更为集中，因此能承受更高的稀疏度；而较高的熵值则意味着重要性分布更为分散，应采取保守的剪枝策略。EcoPrune系统基于熵值指导，提出了两种优化方案：其一为区间约束方案，通过高斯调整增强区间分配精度；其二为无约束概率方案，利用S型函数将熵值衍生的敏感度映射至稀疏度。

我们通过将EcoPrune与SparseGPT（Frantar & Alistarh，2023）集成进行评估，并在多个主流LLM家族中进行全面实验评估，这些家族具有不同参数规模（从7B到72B）和架构（例如LLaMA3（Dubey 等人，2024）、Qwen2.5（Qwen 等人）。，2025），Qwen3（Yang 等人，2025）。实验结果表明，EcoPrune始终优于最先进的LLM剪枝技术。例如，在50%稀疏度下，与 SOTA 方法相比，EcoPrune-A/EcoPrune-B将WikiText-2上的LLaMA3-8B困惑度降低了0.80/0.73，并将平均准确率提高了0.79%/0.71%。在DeepSparse（Kurtic 等人，2025）推理引擎上评估时，EcoPrune在CPU上实现了70%稀疏度下的1.5倍端到端加速。

总体而言，本研究的贡献如下：

- EcoPrune两阶段框架：我们提出一种框架，该框架将预剪枝重要性集中与权重级非线性稀疏分配相结合，同时将熵作为优化目标（第一阶段）和敏感性度量（第二阶段）。
- 非线性稀疏性分配：我们提出两种新型稀疏性分配策略：范围约束（高斯调整）和无约束（基于Sigmoid函数）。
- 具有前景的实证结果：针对LLaMA-3/Qwen-2的广泛实验。图5/-3显示，EcoPrune在70%稀疏率下始终优于最先进的LLM剪枝方法，可实现高达5%的绝对准确率提升。

2. 相关工作

2.1. LLM的剪枝方法

剪枝通过去除冗余参数同时保持模型质量来提高LLM推理效率。现有方法通常分为结构化剪枝（Ma 等人，2023；An 等人，2024），其移除高层组件（如头/神经元）和非结构化剪枝。Li等人，2024），该方法会移除单个权重。代表性方法包括幅度剪枝（Jaiswal等人，2023）、通过二阶信息进行分层重构的SparseGPT（Frantar & Alistarh，2023），以及利用权重幅度和激活统计量估计重要性的Wanda（Sun 等人，2023）。

2.2. 非均匀稀疏性分配

LLM剪枝中的关键问题在于稀疏度分配，因为不同层和矩阵对模型质量的贡献程度不一。先前的研究（Yin 等人，2024；Chen 等人，2025；Shao 等人，2024）突破了均匀稀疏性的限制，主要在层级或权重层级采用异质分配。OWL（Yin 等人，2024）为具有更多离群值统计量的层分配较低稀疏度，而DLP（Chen 等人，2025）利用稳健的权重和激活统计量对层进行排序，无需依赖手动调整的离群值阈值。在更细粒度层面，PrunerGPT（Shao 等人，2024）通过海森矩阵迹相关信号为每个矩阵分配稀疏度，并将敏感度排名线性映射到有界区间$[R-\alpha, R+\alpha]$，但其规则在重尾或聚类分数分布下可能过于僵化，并可能产生额外的二阶估计成本。

2.3. 计算不变性与重要性塑造

近期研究（Ashkboos 等人，2024a；b；Liu 等人，2024；Gu等人，2025）表明，通过Transformer中的计算不变性，重新参数化可以使模型更易于压缩：某些正交变换可以在不改变输入-输出函数的情况下插入。SliceGPT（Ashkboos 等人，2024a）形式化了这一特性，而QuaRot（Ashkboos 等人，2024b）和Spinquant（Liu 等人，2024）利用旋转来重新分配离群值以实现低比特量化。对于剪枝，DenoiseRotator（Gu 等人，2025）提出了一种重要性塑形视角，通过学习最小化归一化重要性分数熵的正交旋转，从而获得更集中的重要性分布并提高剪枝鲁棒性。

3. 方法学

本节阐述EcoPrune的整体框架。我们首先提出问题并界定关键挑战，随后描述EcoPrune如何通过重要性集中和非线性稀疏分配来解决这些问题。

3.1. 问题定义

考虑一个具有L层和权重W=的变压器$\{W_{i,j}\}$，其中$i \in \{1, \ldots, L\}$表示层索引，j表示层内矩阵索引。一种后训练剪枝方法

1，EcoPrune 利用所得熵值指导真实剪枝（Frantar & Alistarh，2023；Dong 等，2024；

□ 审稿人：CIny。本文正在由inML 2q26进行严格审阅。未经许可，严禁分享、转载或传播。

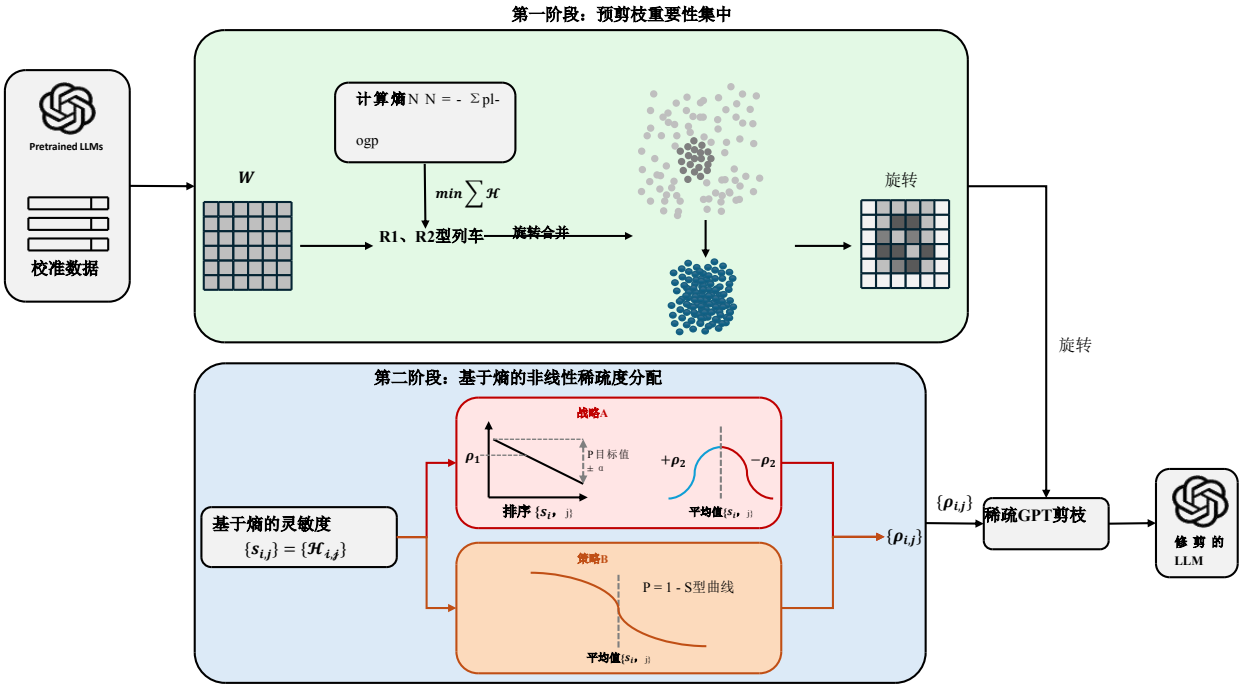

*图1.*EcoPrune框架概述。EcoPrune包含两个阶段。第一阶段（预剪枝重要性集中）将可学习的正交旋转*R1*、*R2*插入每个Transformer层，并通过最小化归一化重要性分布的信息熵进行优化，生成具有更高重要性集中度的旋转权重W_{ROT}。第二阶段（基于熵的非线性稀疏度分配）将每个矩阵的熵值作为灵敏度信号进行重用，并通过两种非线性分配策略分配权重级稀疏度。最后，将分配的$\rho_{i,j}$与SparseGPT结合，对W_{ROT}进行一次性剪枝，得到剪枝后的模型。

目标是在最小化局部重构误差的同时，找到具有全局目标稀疏度ρ_{target}的稀疏权重$\hat{W}_{i,j}$：

$$\hat{W}_{i,j} = \arg\min_{W'_{i,j}} ||W_{i,j}X_{i,j} - W'_{i,j}X_{i,j}||_2^2,$$

$$\rho_{target} = \frac{1}{|W|}\sum_{i,j}(\rho_{i,j})$$

其中$X_{i,j} \in \mathbb{R}^{d_{in},n}$是$W_{i,j} \in \mathbb{R}^{d_{out},d_{in}}$的校准激活，$||\cdot||_2^2$是$\ell_2$范数，$|W|$是矩阵的数量，而$\rho_{i,j} \in [0,1]$是矩阵$(i,j)$的分配稀疏度。EcoPrune通过两阶段设计（第一阶段：逐层正交旋转；第二阶段：权重层级稀疏性分配）提升了高稀疏性条件下的剪枝鲁棒性。

3.1.1. 逐层旋转

第一阶段学习每层（层内共享）的一组小规模正交矩阵，用于旋转该层中的所有矩阵，从而在不改变模型函数的情况下实现一致的重参数化。

3.1.2. 基于权值的稀疏分配

在重新参数化后，第二阶段确定矩阵间非均匀稀疏比$\rho_{i,j}$，该过程基于固定的全局稀疏度。系统预算。具体而言，我们实施一种形式为的总体稀疏性约束$\rho_{target} = \frac{1}{|W|}\sum_{i,j}(\rho_{i,j})$，同时允许每个$(i,j)$根据其敏感信号采用不同的稀疏度。

3.1.3. 集成实现

经过上述两个阶段后，每个矩阵都有一个分配的稀疏度$\{\rho_{i,j}\}$。我们通过将所有权重级别的稀疏度比率共享偏移量进行移动，应用一个简单的全局校准，使它们的平均值与$\rho_{目标}$相匹配。然后我们使用标准的一次性方法（例如，稀疏GPT（Frantar & Alistarh，2023）采用校准后的稀疏性。

3.2. 预剪枝重要性集中度

3.2.1. 重要性集中公式化 考虑一个线性层$W \in R^{d_{in},d_{out}}$，其校准激活为X，并令$S=S_{i,j}$为任意非负重要性评分矩阵，该矩阵用于剪枝方法（Sun 等人，2023；Frantar & Alistarh，2023；Shao 等人，2024）。这些方法可视为选择剪枝索引P以最小化输出重构偏差，这近似等同于最小化P上的重要性总和。除了选择低分权重外，我们还可以通过变换重塑重要性分布本身。

第一阶段：预剪枝重要性集中

机密审稿人副本。本手稿正在接受ICML 2026的双盲评审。未经授权的共享、再分发或披露均属禁止。

严禁。

正式表述为：

$$\min_{W',T_W,T_X} ||T_W(W)T_X(X) - T_W(W')T_X(X)||_2^2 \approx \min_{\mathcal{P},T_S} \sum_{(i,j)\in\mathcal{P}} T_S(S)_{i,j} \tag{1}$$

其中（T_W，TX）对权重和输入（例如正交）进行变换，而T_S是S上的诱导变换。

3.2.2. 归一化重要性分数的熵最小化

直接优化等式1由于P的组合选择和基于排序的剪枝不可微性而困难。因此我们采用DenoiseRotator（Gu 等人，2025）中的替代目标函数，并最小化归一化重要性的信息熵以促进集中。具体而言，令T_S可学习，计算S'=T_S（S），并在组G，｛（i，j）｝内进行归一化（例如根据旋转位置为行/列/矩阵）：

$$p_{i,j} = \frac{T_S(S)_{i,j}}{\sum_{(i,j)\in\mathcal{G}} T_S(S)_{i,j}}, \qquad \mathcal{H}(P) = -\sum_{(i,j)\in\mathcal{G}} p_{i,j}\log p_{i,j} \tag{2}$$

其中P=$\{p_{i,j}\}$是G上的离散分布。我们通过最小化来学习共享变换$\min_{T_S}\sum_{\mathcal{G}} H(P)$，该方法在剪枝前将重要性集中于更少的参数上。

3.2.3. 正交实例化与优化

如图1所示，EcoPrune通过两对可学习的正交矩阵实例化（T_W，TX），并将它们整合到每个Transformer层中。

层级旋转（*R1*）：在每个Transformer层的起始和结束时应用一对正交矩阵R_1和*RT1*。 R $^{d_{hidden}\times d_{hidden}}$；$R_1$插入在RMSNorm和残差相加之前，而*RT1*则在这些操作之后应用。

注意力层级旋转（*R2*）：在自注意力机制中，另一对正交矩阵R_2和*RT2*分别应用于价值（V）和输出（O）投影。

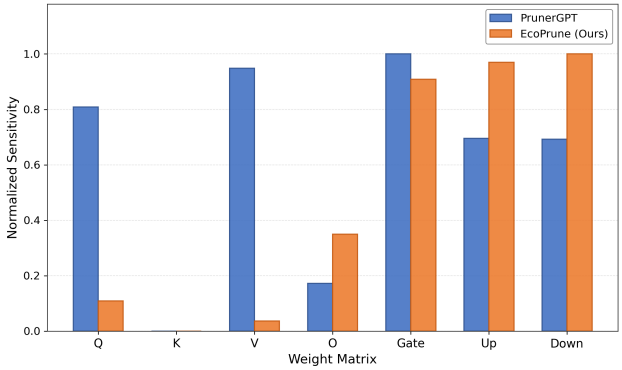

*图2.*PrunerGPT敏感性与我们基于熵的敏感性在LLaMA-3-8B上的比较（在相同层内归一化）。我们报告了关键权重矩阵（Q/K/V/O投影及 MLP 门/上/下）的标准化得分。

对于输出(O)投影，我们有：

$$W' = T_W(W) = R_1^T W R_2, \quad X' = T_X(X) = R_2^T X, \quad W'X' = R_1^T W X \tag{3}$$

其中W表示其形状为(d_{hidden}，*dhidden*)的权重矩阵，X表示其变换前形状为(d_{hidden}，*len* × *bsz*)的输入。

训练过程中，我们仅优化正交矩阵，同时冻结预训练权重和激活值，所有正交矩阵均初始化为单位矩阵。由于Transformer层内的所有线性层共享R_1和R_2，分层目标函数会统计所有受影响层及其归一化组的熵值总和：

$$Loss(R_{1,i}, R_{2,i}) = \sum_{l\in\mathcal{L}_i}\sum_{\mathcal{G}\in l}\mathcal{H}(P_{\mathcal{G}}) \tag{4}$$

其中$\mathcal{L}_i$表示第i个变压器层内所有线性层的集合。

训练完成后，除层边界处的正交矩阵外，其余所有正交矩阵均被合并至相应的权重矩阵中。如附录所示。A，由此产生的旋转集中了重要性，并提高了后续对合并权重进行剪枝的鲁棒性。

3.3. 基于熵的非线性稀疏分配

3.3.1. 熵-基敏感度信号PrunerGPT（Shao 等人，2024）提出了一种混合稀疏剪枝策略，该策略根据敏感度信号为不同权重矩阵分配不同的稀疏度比率。沿此思路，EcoPrune使用重要性集中后计算的权重熵作为熵基敏感度信号。

正式表述为：

机密审稿人副本。本手稿正在接受ICML 2026的双盲评审。未经授权的共享、再分发或披露均属禁止。

严禁。

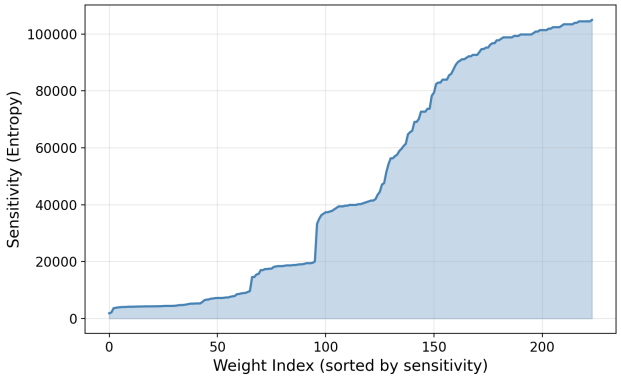

*图3.*LLaMA-3-8B各层权重敏感度分布（按升序排列）。每个点代表基于熵的权重矩阵敏感度。

令$W=\{W_{i,j}\}$ 表示所有权重矩阵的集合，$H_{i,j}$为经过重要性集中后旋转矩阵计算得到的熵值。我们将矩阵敏感度定义为

$$s_{i,j} \triangleq H_{i,j} \tag{5}$$

当较小的$s_{i,j}$表示重要性分布更为集中时，该矩阵对移除大部分权重具有更强的容错性，因此应获得更高的稀疏比。反之，熵值较大的矩阵则分配较低的稀疏比，以避免剪除分布但关键的权重元素。

如图所示。2，PrunerGPT对注意力投影（尤其是Q和V）赋予了更高的敏感度，而我们的基于熵的信号则将 MLP 矩阵（*Gate*/*Up*/*Down*）列为更为关键。这与现代大语言模型中门控 MLP 模块的作用一致：*Gate*和*Up*控制激活流和特征扩展，而*Down*将扩展后的特征投射回残差流，因此对这些矩阵进行激进剪枝会更直接损害整体模型容量和零样本性能。通过为*Gate*/*Up*/*Down*分配较低稀疏度，并对重要性更集中的矩阵进行更激进剪枝，EcoPrune能更好地保留模型质量，这在我们的实验中通过改进的困惑度和零样本准确率得以体现。

3.3.2. 非线性稀疏分配

如图3所示，基于熵的各矩阵敏感性呈现高度不均匀性，并表现出明显的非线性模式。这表明，严格的线性秩-稀疏度映射可能低估了具有极端敏感性的矩阵。基于这一观察，我们设计了两种非线性权重级稀疏度分配策略：EcoPrune-A（高斯调整范围约束分配）和EcoPrune-B（基于Sigmoid的无约束分配）。

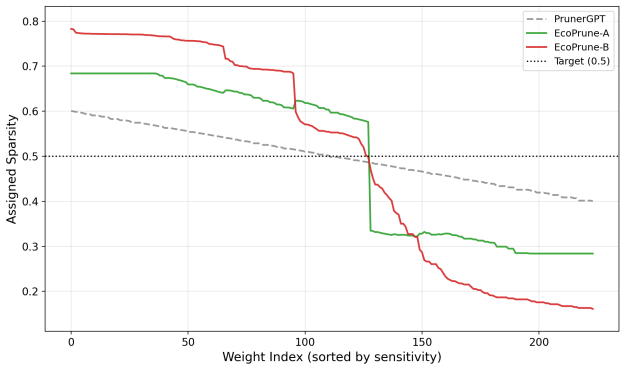

*图4.*LLaMA-3-8B数据集上不同方法稀疏性分配策略的对比。所有方法均经过全局归一化处理，以实现相同的50%目标稀疏度。

EcoPrune-A：高斯校正范围约束分配

该策略保留了PrunerGPT中使用的范围约束（Shao 等人，2024）：所有矩阵通过基于区间的线性分配被分配到[$\bar{\rho}_{目标}-\acute{\kappa}$，$\bar{\rho}_{目标}+\acute{\kappa}$]范围内，从而在固定的全局稀疏度预算下稳定分配。随后我们添加高斯调整，使得具有极端敏感性的矩阵获得更强的调整。

基于区间$\bar{\rho}^1$：我们首先按敏感度升序对矩阵进行排序$s_1 \leq s_2 \leq \cdots \leq s_{|W|}$，其中$|W|$表示矩阵数量，并令$rank(i,j) \in \{1, \ldots, |W|\}$表示该排序中$s_{i,j}$的秩。随后我们按如下方式计算基于区间的稀疏度：

$$L=\bar{\rho}_{目标}-\acute{\kappa},\ R=\bar{\rho}_{目标}+\acute{\kappa},$$

$$\rho^1_{i,j} = L + \frac{rank(i,j)-1}{|W|-1}(R-L) \tag{6}$$

高斯调整$\bar{\rho}^2$: 我们首先计算每个矩阵到平均灵敏度的距离：

$$\mu = \frac{1}{|W|}\sum_{(i,j)} s_{i,j}, \tag{7}$$

$$d_{i,j} = s_{i,j} - \mu$$

直观上，如果$d_{i,j}<0$（熵小于均值），$W_{i,j}$的稀疏性应增加；如果$d_{i,j}>0$（熵大于均值），$W_{i,j}$的稀疏性应减少。

随后我们按以下方式计算高斯调整稀疏度：

$$\sigma^2 = \frac{1}{|W|}\sum_{(i,j)}(s_{i,j}-\mu)^2, z_{i,j} = \frac{d_{i,j}}{\sigma}, \tag{8}$$

$$\rho^2_{i,j} = -\gamma \cdot sign(d_{i,j}) \cdot exp(-\frac{z^2_{i,j}}{2})$$

机密评审员副本本手稿正在接受ICML 2026的双盲评审。未经授权的共享、再分发或披露均属禁止。

严禁。

其中 $\check{y}$ >0 控制高斯调整的幅度 A) 以及 S 型曲线的温度 μ= 1.0（策略终止期

最后，我们将基于区间的稀疏性与高斯调整稀疏性相结合：

$$\mathbb{R}_{i,j}=\mathbb{R}_{1i,j}+\mathbb{R}_{2i,j} \tag{9}$$

EcoPrune-B：基于Sigmoid的无约束分配

该策略避免了基于区间的稀疏性分配，而是直接采用单调S型函数将敏感性映射至稀疏性。这使得分配过程变得简单、可微分且天然非线性。

$$\rho_{i,j} = 1 - \frac{1}{1 + exp(\delta \cdot z_{i,j})} \tag{10}$$

其中 μ >0是Sigmoid映射的温度参数，$z_{i,j}$是等式8中的归一化距离。由于Sigmoid函数严格单调，$d_{i,j}$< 0总会产生更大的$\mathbb{R}_{i,j}$，而$d_{i,j}$> 0则产生更小的$\mathbb{R}_{i,j}$，无需排序即可匹配我们的熵-稀疏排序。

图4展示了EcoPrune-A和EcoPrune-B与PrunerGPT（例如基于区间的分配）相比如何生成非线性稀疏度分配曲线（Shao 等人，2024），在保持固定全局稀疏度预算的同时，将更极端的稀疏度分配给具有极端熵敏感性的矩阵。

4. 实验

4.1. 实验设置

模型与任务：我们在近期开源大语言模型上评估EcoPrune，包括 LLaMA3-8B（Dubey 等人，2024）、Qwen2.5-7B/14B/72B（Qwen 等人，2025）以及Qwen 3-8B/14B/32B（Yang 等人，2025）。我们通过WikiText-2（Merity 等人，2017）和C4（Raffel 等人，2020）上的困惑度衡量生成质量，并报告 PIQA（Bisk 等人，2020）、WinoGrande（Sakaguchi 等人，2021）、HellaSwag（Zellers 等人，2019）、ARC-e和ARC-c（Clark等人，2018），使用LM评估套件（Gao 等人，2021）的默认设置。

基线：我们采用统一的训练后单次剪枝设置，保持全局稀疏度固定（50%）。EcoPrune有两种变体（第3.3.2节）：EcoPrune-A（高斯调整范围约束分配）和EcoPrune-B（基于Sigmoid的无约束分配）。我们使用与DenoiseRotator相同的校准集（Gu 等人，2025）：从C4数据集（Raffel 等人，2020）中采样的128条长度为2048（标记）的序列。

实现细节：我们使用Adam优化器（学习率=0.01）对正交矩阵（第3.2节）进行2000步优化，并将高斯调整的幅度设置为 $\check{y}$= 0.12（strat-B)实验在 NVIDIA H800显卡（80GB显存）上运行。

4.2. 主要结果

生成能力（困惑度）：我们在WikiText-2和C4数据集上采用困惑度评估50%稀疏度下的语言模型性能。所有测试模型（LLaMA-3-8B、Qwen2.5-7B/14B/72B，以及Qwen3-8B/14B/32B），EcoPrune-A和EcoPrune-B在所有对比方法中始终取得最低困惑度。例如，在LLaMA-3-8B（表1）上，EcoPruneA达到6.79/10.54（WikiText-2/C4），EcoPruneB达到6.86/10.69，优于DenoiseRotator（7.59/11.86）（Gu 等人，2025）。更大模型的结果见附录B。

零样本结果：我们报告了ARC-c、ARC-e、HellaSwag、PIQA、WinoGrande及其在50%稀疏度下的平均零样本准确率。EcoPrune在所有评估模型中实现了最佳平均准确率，而某些基线模型在特定任务上具有竞争力（例如PrunerGPT（Shao 等人，2024）在WinoGrande上的表现，以及DenoiseRotator（Gu 等人，2025）在 PIQA 上针对特定模型的表现；见表1）。附录B中包含了更大模型的零样本结果。

4.3. 消融研究

4.3.1. ECOPRUNE 组件上的消融

表2展示了EcoPrune在WikiText-2和C4数据集上基于50%稀疏度的困惑度评估结果，重点分析了其关键组件在LLaMA-3-8B数据集上的表现。SparseGPT仅采用SparseGPT（Frantar & Alistarh，2023）进行剪枝，不使用重要性集中（IC）或非均匀分配；无IC采用线性分配而不使用IC；统一IC支持IC与矩阵间均匀分配；线性IC则将IC与线性非均匀分配相结合。

与无IC和稀疏GPT相比，无IC将困惑度从9.57/14.22提升至8.47/13.02，这表明即使不进行重要性集中，重新分配矩阵间的稀疏性仍具有显著优势。线性IC与单向IC的对比结果进一步验证了非均匀分配的有效性。相较于单向IC和稀疏GPT，单向IC将困惑度从9.57/14.22提升至7.59/11.86，说明重要性集中能通过优化参数重要性分布，使剪枝过程更具鲁棒性。相较于EcoPrune-A/EcoPrune-B和线性IC，EcoPrune-A和EcoPrune-B分别将困惑度从7.22/11.20提升至6.79/10.54和6.86/10.69，这表明非线性分配能更精准匹配矩阵间的敏感性分布，在保持相同剪枝稀疏度的前提下，实现了更优的剪枝效果。

其中 $\check{y}$ >0 控制高斯调整的幅度 A) 以及 S 型曲线的温度 μ= 1.0（策略

机密审稿人副本。本手稿正在接受ICML 2026的双盲评审。未经授权的共享、再分发或披露均属禁止。

严禁。

模型	方法	零样本准确率（%）↑						困惑↓	
		ARC-正性	ARC-e	HellaSwag	PIQA	葡萄大	平均	维基文本2	C4
LLaMA-3-8B	稠密	52.73	77.78	79.19	80.96	72.93	72.72	6.14	9.44
	OWL（Yin 等人，2024）	45.65	69.87	73.04	77.64	72.69	67.78	9.60	14.11
	DLP（Chen 等人，2025）	45.73	71.42	72.27	77.69	71.03	67.63	9.99	14.56
	PrunerGPT（Shao 等人，2024）	46.59	71.17	74.17	77.64	72.38	68.39	8.47	13.02
	DenoiseRotator（Gu 等人，2025）	49.06	76.73	75.73	79.65	**73.24**	70.88	7.59	11.86
	EcoPrune-A	50.43	**77.06**	77.47	**80.36**	73.01	**71.67**	**6.79**	**10.54**
	EcoPrune-B	**50.51**	76.73	**77.49**	80.03	73.16	71.59	6.86	10.69
Qwen2.5-7B	稠密	51.37	77.61	78.92	80.14	72.85	72.18	6.85	11.88
	OWL（Yin 等人，2024）	47.87	74.20	72.85	77.42	72.06	68.88	8.56	13.74
	DLP（Chen 等人，2025）	43.52	67.68	71.52	77.48	69.30	65.90	10.26	15.12
	PrunerGPT（Shao 等人，2024）	48.98	76.94	75.23	78.45	**72.22**	70.36	7.81	12.96
	DenoiseRotator（Gu 等人，2025）	51.62	77.99	76.39	79.00	71.90	71.38	7.63	12.77
	EcoPrune-A	**52.22**	78.24	77.94	79.49	71.51	71.88	**7.20**	**12.28**
	EcoPrune-B	51.62	**78.28**	**78.18**	**79.92**	71.82	**71.97**	7.21	12.31
Qwen2.5-14B	稠密	58.96	79.34	82.95	82.1	75.69	75.81	5.29	10.35
	OWL（Yin 等人，2024）	53.67	80.89	77.24	79.87	72.85	72.90	7.34	12.14
	DLP（Chen 等人，2025）	53.41	80.56	75.66	78.45	72.69	72.16	8.86	13.52
	PrunerGPT（Shao 等人，2024）	56.66	**82.53**	78.06	80.36	73.56	74.23	6.96	11.73
	DenoiseRotator（Gu 等人，2025）	56.23	79.80	80.39	81.34	**76.24**	74.80	6.52	11.31
	EcoPrune-A	58.79	80.51	**82.08**	**82.10**	74.74	75.64	5.93	10.82
	EcoPrune-B	**59.04**	80.72	81.95	81.77	74.90	**75.68**	**5.86**	**10.78**
Qwen3-8B	稠密	56.23	80.93	74.98	77.80	67.72	71.53	9.72	15.43
	OWL（Yin 等人，2024）	53.92	79.00	69.50	76.55	**71.51**	70.10	11.69	17.85
	DLP（Chen 等人，2025）	52.13	76.94	66.67	76.50	69.22	68.29	14.45	20.33
	PrunerGPT（Shao 等人，2024）	55.29	77.74	70.29	**77.15**	70.64	70.22	10.98	16.98
	DenoiseRotator（Gu 等人，2025）	54.52	79.08	71.76	**77.15**	67.40	69.98	10.63	16.69
	EcoPrune-A	**56.57**	79.08	73.31	77.09	68.19	70.85	**10.35**	**16.28**
	EcoPrune-B	55.80	**79.50**	**73.39**	76.93	68.82	**70.89**	10.57	16.50
Qwen3-14B	稠密	60.41	82.95	78.95	79.82	73.09	75.04	8.64	13.82
	OWL（Yin 等人，2024）	54.95	75.38	74.65	78.40	72.22	71.12	10.14	15.73
	DLP（Chen 等人，2025）	54.35	77.10	72.70	77.53	71.19	70.58	12.54	18.14
	PrunerGPT（Shao 等人，2024）	55.38	77.27	74.65	78.07	71.51	71.38	9.90	15.24
	DenoiseRotator（Gu 等人，2025）	59.04	82.11	76.81	78.73	**72.45**	73.83	9.53	14.85
	EcoPrune-A	**61.01**	**82.32**	77.84	79.76	71.90	**74.57**	8.93	**14.28**
	EcoPrune-B	58.96	81.10	**77.96**	**80.30**	71.35	73.94	**8.89**	14.36

*表1.*展示了不同LLM家族和规模在50%稀疏度下的结果。e报告了五个基准测试（ARC-c/ARC-e/HellaSwag/ PIQA /WinoGrande）上的零样本准确率，以及WikiText2和C4上的困惑度。↑/↓表示结果越高/越低越好。

4.3.2. 不同稀疏度的消融

在WikiText2/C4数据集上的表现。相较于最强基线模

表3展示了LLaMA-3-8B在更高目标稀疏度（60%和70%）下的实验结果，这些条件比我们主要研究中使用的50%稀疏度更具挑战性。随着稀疏度的增加，所有基准模型均出现显著性能下降，而EcoPrune模型仍展现出明显更强的鲁棒性。这表明，我们采用的熵引导重要性集中与非线性分配策略，在强剪枝条件下能更好地保留关键计算资源。

在60%稀疏度下，EcoPrune以68.40的平均准确率和7.66/11.90的困惑度（perplex）实现了最佳整体性能。型DenoiseRotator，EcoPrune平均准确率提升2.06%，困惑度降低1.67/2.24。

在70%稀疏度下，EcoPrune展现出更为显著的优势，平均准确率达到65.38，困惑度为10.14/15.16。与DenoiseRotator相比，EcoPrune使平均准确率提升5.15，并将困惑度降低5.00/5.99。

总体而言，这些结果表明，随着稀疏度的增加，EcoPrune提供了更强的剪枝鲁棒性，且其相对于先前方法的相对改进在更高稀疏度水平下更为显著。

机密审稿人副本。本手稿正在接受ICML 2026的双盲评审。未经授权的共享、再分发或披露均属禁止。

严禁。

方法	IC	L	不均匀的 线性的	圣A	ST. B	困惑↓ 维基文本2	C4
稀疏GPT						9.57	14.22
w/o-IC			✓			8.47	13.02
uni-IC	✓					7.59	11.86
线性集成电路	✓		✓			7.22	11.20
EcoPrune-A	✓			✓		6.79	10.54
EcoPrune-B	✓				✓	6.86	10.69

*表2.*EcoPrune组件在LLaMA-3-8B数据集上以50%稀疏度进行的消融研究，通过WikiText2和C4数据集的困惑度评估。SparseGPT：该方法仅采用均匀剪枝策略。w/o-IC：该方法采用线性分配（例如基于区间的分配）且不进行重要性集中。uniIC：该方法在重要性集中后采用均匀剪枝策略。linear-IC：该方法在重要性集中后采用线性分配。

稀疏性	方法	Avg. Acc. ↑	WikiText2 ↓	C4 ↓
60%	猫头鹰	60.68	14.59	19.49
	DLP	61.26	14.58	19.20
	Pruner-GPT	61.72	12.07	17.19
	Denois-eRotator	66.34	9.33	14.14
	EcoPrune	**68.40**	**7.66**	**11.90**
70%	猫头鹰	48.35	35.08	39.98
	DLP	49.93	35.83	35.50
	Pruner-GPT	49.72	26.44	33.62
	Denois-eRotator	60.23	15.14	21.15
	EcoPrune	**65.38**	**10.14**	**15.16**

*表3.*LLaMA-3-8B模型在60%和70%稀疏度下的结果。我们报告了WikiText2和C4数据集上的平均零样本准确率和困惑度。

4.3.3. 非线性映射上的消融 HYPERPARAMETERS

我们进一步分析了两种非线性分配策略中关键超参数对50%稀疏度LLaMA-3-8B模型的影响。表。4变化策略A中高斯调整的幅度γ，而表6变化策略B中S型映射的温度δ。

对于策略A，表4显示EcoPrune-A在合理范围内的γ下保持相对稳定。增加γ会增强高斯调整效果，从而放大基于极端熵信号矩阵的稀疏性对比，但过度调整可能略微损害零样本准确率。在我们的设置中，γ=0.12实现了最佳整体平衡，在WikiText2和C4数据集上均保持最低（或接近最低）困惑度的同时，达到最高平均准确率。

对于策略B，表6表明EcoPrune-B对S型温度δ更为敏感。较小的δ会产生更平滑的映射，并在困惑度上略占优势，而较大的δ会使映射更加

设置	Avg. Acc. ↑	WikiText2 ↓	C4 ↓
$\gamma = 0.10$	71.57	6.81	10.57
$\gamma = 0.12$	71.67	6.79	10.54
$\gamma = 0.15$	71.19	6.79	10.53

表4。在50%稀疏度条件下，对LLaMA-3-8B数据集进行高斯调整幅度γ的消融研究（策略A）。

设置	Avg. Acc. ↑	WikiText2 ↓	C4 ↓
$\delta = 0.9$	71.27	6.83	10.63
$\delta = 1.0$	71.59	6.86	10.69
$\delta = 1.1$	71.26	6.92	10.78

*表5.*楔形映射温度消融研究δ在LLaMA-3-8B上采用50%稀疏度的策略B。

模型	延迟（毫秒）	加速
LLaMA-3-8B	4133.56	1.0×
EcoPrune	2783.78	1.5×

*表6.*使用DeepSparse（Kurtic 等人，2025）推理引擎在70%稀疏度下对LLaMA-3-8B进行端到端推理的延迟与加速比。我们测量了从C4中采样的100个序列的平均延迟，并报告了相对于密集模型的相对加速比。

具有攻击性且会降低剪枝鲁棒性。总体而言，δ=1.0在平均准确率和困惑度方面提供了平衡的性能，因此我们将其作为默认设置。

4.4. 推理加速分析

如表6所示，我们使用从C4中采样的100个序列，采用DeepSparse [1]（Kurtic 等人，2025）推理引擎，在70%稀疏度下对LLaMA-3-8B进行端到端推理基准测试。EcoPrune实现了1。相较于密集模型，EcoPrune实现了5 ×的加速比，这表明其稀疏性带来的实际运行时间提升，远超单纯剪枝鲁棒性的改进。这说明EcoPrune在高稀疏度下的模型质量与部署效率之间，找到了一个有效的平衡点。

5. 结论

本文提出名为EcoPrune的双阶段后训练剪枝框架，专为大型语言模型设计。该框架通过结合重要性集中与非线性稀疏度分配，显著提升了模型的鲁棒性。具体实现时，EcoPrune首先通过熵最小化学习正交变换来重塑重要性分布，随后将生成的熵值作为敏感性信号，在固定全局稀疏度条件下，采用非线性分配策略对权重层级进行稀疏度优化。实验表明，相较于强剪枝基线模型，该框架在相同稀疏度水平下，能持续提升多类大语言模型的困惑度和零样本准确率。

[1] https://github.com/neuralmagic/deepsparse

机密审稿人副本。本手稿正在接受ICML 2026的双盲评审。未经授权的共享、再分发或披露均属禁止。

严禁。

参考文献

Achiam, J., Adler, S., Agarwal, S., Ahmad, L., Akkaya, I., Aleman, F. L., Almeida, D., Altenschmidt, J., Altman, S., Anadkat, S., 等. GPT-4技术报告.*arXiv预印本 arXiv:2303.08774*,2023.

安Y、赵X、余T、唐M和王J. 基于波动的大型语言模型自适应结构剪枝方法. 收录于*《AAAI人工智能会议论文集》*第38卷，第10865–10873页，2024年。

Ashkboos，S.，Croci，M. L.，Nascimento，M. G. d.，Hoefler，T.，和 Hensman，J. Slicegpt: 通过删除行和列来压缩大型语言模型。*arXiv预印本 arXiv: 2401.15024*，2024a.

Ashkboos，S.，Mohtashami，A.，Croci，M. L.，Li，B.，Cameron，P.，Jaggi，M.，Alistarh，D.，Hoefler，T.，和 Hensman，J. Quarot: 旋转llms中的无离群值4位推断.*神经信息处理系统进展*，37:100213–100240,2024b.

Bisk，Y.，Zellers，R.，Gao，J.，Choi，Y.，等. Piqa：自然语言中物理常识推理。*《美国人工智能协会（AAAI）人工智能会议论文集》*，第34卷，第7432–7439页，2020年。

蔡瑞、穆拉利达兰、海因里希、尹宏、王志、考茨、莫尔恰诺夫。Flextron：多语言一体化的灵活大型语言模型。*arXiv预印本 arXiv:2406.10260*，2024年。

Chen，Y.，Cheng，B.，Han，J.，Zhang，Y.，Li，Y.，and Zhang，S. DLP: Dynamic layerwise pruning in large language models. In *Forty-second International Conference on Machine Learning*，2025. URL https://openreview.net/forum？id=11id5ppGZ8.

Clark，P.，Cowhey，I.，Etzioni，O.，Khot，T.，Sabharwal，A.，Schoenick，C.，and Tafjord，O. 你以为自己已经解决了问答问题？试试arc，这个ai2推理挑战。*arXiv预印本 arXiv:1803.05457*，2018.

董鹏、李丽、唐哲、刘曦、潘旭、王强、楚曦. Prunerzero: 从零开始为大型语言模型演化符号剪枝度量. *arXiv预印本 arXiv:2406.02924*，2024.

Dubey, A., Jauhri, A., Pandey, A., Kadian, A., Al-Dahle, A., Letman, A., Mathur, A., Schelten, A., Yang, A., Fan, A., 等.模型中的羊驼3群.*arXiv预印本 arXiv: 2407.21783*,2024年.

Dumitru，R.-G.，Clotan，P. I.，Yadav，V.，Peteleaza，D.，和 Surdeanu，M. 变化是唯一不变的：基于层冗余的动态llm切片。*计算语言学协会会议论文集：EMNLP 2024*，第9912–9920页，2024年。

Frantar，E. 和 Alistarh，D. Sparsegpt：大规模语言模型可通过单次训练实现精准剪枝。发表于*国际机器学习会议*，第10323–10337页。 PMLR，2023年。

Gao, L., Tow, J., Biderman, S., Black, S., DiPofi, A., Foster, C., Golding, L., Hsu, J., McDonell, K., Muennighoff, N., et al. 《少样本语言模型评估框架》 *Zenodo*,2021年.

顾T.、刘B.、肖B.、曾K.、刘J.和钱Y. 去噪旋转器：通过重要性集中增强llms的剪枝鲁棒性。*arXiv预印本 arXiv:2505.23049*，2025年。

Guo, D., Yang, D., Zhang, H., Song, J., Zhang, R., Xu, R., Zhu, Q., Ma, S., Wang, P., Bi, X., et al. Deepseek-r1:通过强化学习激励LLM的推理能力.*arXiv预印本 arXiv: 2501.12948*,2025年.

Jaiswal, A., Liu, S., Chen, T., Wang, Z., 等. 大型预训练模型中本质稀疏性的出现:关键权重.*神经信息处理系统进展*,36:38887–38901,2023.

Kurtic, E.库兹涅杰列夫、弗兰塔尔、戈因夫、潘迪特、阿加瓦拉、阮、马克斯、库尔茨和阿利斯塔尔。稀疏微调加速大型语言模型推理。《增强LLM性能：效能、微调与推理技术》，*第7卷第83页，2025年。*

李G、唐Y和张W. Lorap：Transformer子层应采用差异化的结构化压缩方法应用于大型语言模型。*arXiv预印本 arXiv:2404.09695*，2024年。

刘Z.、赵C.、费多罗夫I.、索兰B.、乔杜里D.、克里希纳莫尔蒂R.、钱德拉V.、田Y.与布兰克沃特T.《Spinquant：基于学习旋转的Llm量子化方法》 *arXiv预印本 arXiv:2405.16406*，2024.

马X、方G、王X. Llm-pruner：大型语言模型的结构剪枝研究.*神经信息处理系统进展*，36:21702–21720,2023.

但，X.、徐、M.、张、Q.、袁、Q.、王、B.、林、H.、卢、Y.、韩、X.和陈、W. Shortgpt：大型语言模型中的层比预期的更冗余。见*计算语言学协会会议录：ACL 2025*，第20192–20204页，2025年。

梅里蒂，S.，熊，C.，布拉德伯里，J.，与索彻，R.指针哨兵混合模型。在*国际学习表征会议*，2017年。网址 https://openreview.net/forum？id=Byj72udxe。

机密审稿人副本。本手稿正在接受ICML 2026的双盲评审。未经授权的共享、再分发或披露均属禁止。

严禁。

穆拉利达兰、图鲁维克雷·斯里尼瓦斯、乔希、乔乔夫斯基、帕特瓦里、肖伊比、卡坦扎罗、考茨和莫尔恰诺夫。通过剪枝与知识蒸馏构建紧凑型语言模型。《神经信息处理系统进展》，37卷：41076–41102页，2024年。

Qwen，:，杨，A.，杨，B.，张，B.，胡，B.，郑，B.，余，B.，李，C.，刘，D.，黄，F.，魏，H.，林，H.，杨，J.，杜，J.，张，J.，杨，J.，杨，J.，周，J.，林，J.，当，K.，卢，K.，邓，K.，杨，K.，余，L.，李，M.，学，M.，张，P.，朱，Q.，门，R.，林，R.，李，T.，唐，T.，萧，T.，任，X.，任，X.，范，Y.，苏，Y.，张，Y.，万，Y.，刘，Y.，崔，Z.，张，Z.，和邱，Z. Qwen2.5技术报告，2025. URL https://arxiv.org/abs/2412.15115.

Raffel，C.，Shazeer，N.，Roberts，A.，Lee，K.，Narang，S.，Matena，M.，Zhou，Y.，Li，W.，and Liu，P. J. 探索统一文本到文本转换器在迁移学习中的极限.*机器学习研究杂志*，21 (140):1–67,2020.

坂口K.、布拉兹R. L.、巴加瓦图拉C.，以及Choi，Y. Winogrande：大规模对抗性Winograd模式挑战。*ACM通讯*，64(9):99–106,2021年。

邵浩、刘斌和钱勇. 大型语言模型的单次灵敏度感知混合稀疏剪枝.*ICASSP 2024-2024 IEEE国际声学、语音和信号处理会议(ICASSP)*，第11296-11300页. IEEE，2024.

孙M、刘Z、贝尔A和科尔特JZ. 大型语言模型的简单有效剪枝方法.*arXiv预印本 arXiv:2306.11695*，2023.

图弗龙，H.，拉夫里尔，T.，伊扎卡尔，G.，马蒂内，X.，拉肖，M.-A.，拉克鲁瓦，T.，罗齐ère，B.，Goyal，N.，Hambro，E.，Azhar，F.，等. Llama：开放高效的基底语言模型.*arXiv预印本 arXiv:2302.13971*，2023.

杨A、李A、杨B、张B、惠B、郑B、余B、高C、黄C、吕C、郑C、刘D、周F、黄F、胡F、葛H、魏H、林H、唐J、杨J、涂J、张J、杨J、杨J、周J、周J、林J、当K、鲍K、杨K、余L、邓L、李M、薛M、李M、张P、王P、朱Q、门R、高R、刘S、罗S、李T、唐T、尹W、任X、王X、张X、任X、范Y、苏Y、张Y、张Y、万Y、刘Y、王Z、崔Z、张Z、周Z、邱Z。Qwen3技术报告，2025年。网址 https://arxiv.org/abs/2505.09388。

尹L、吴Y、张Z、谢C-Y、王Y、贾Y、李G、贾伊斯瓦尔A.K.、佩切尼兹基M、梁Y、本德斯基M、王Z和刘S. 异常值加权分层稀疏（OWL）：一种将大语言模型剪枝至高稀疏度的隐藏秘方。发表于*第四十一届国际机器学习会议*，2024年。网址https：//openreview.net/forum？id=ahEm3l2P6w。

Zellers，R.，Holtzman，A.，Bisk，Y.，Farhadi，A.，和 Choi，Y. Hellaswag: 机器真的能帮你完成句子吗？ *arXiv预印本 arXiv:1905.07830*，2019.

张Y、白H、林H、赵J、侯L与Cannistraci C.V.《即插即用：大型语言模型的高效后训练剪枝方法》。2024年。

机密审稿人副本。本手稿正在接受ICML 2026的双盲评审。未经授权的共享、再分发或披露均属禁止。

严禁。

A. 重要性分布的可视化

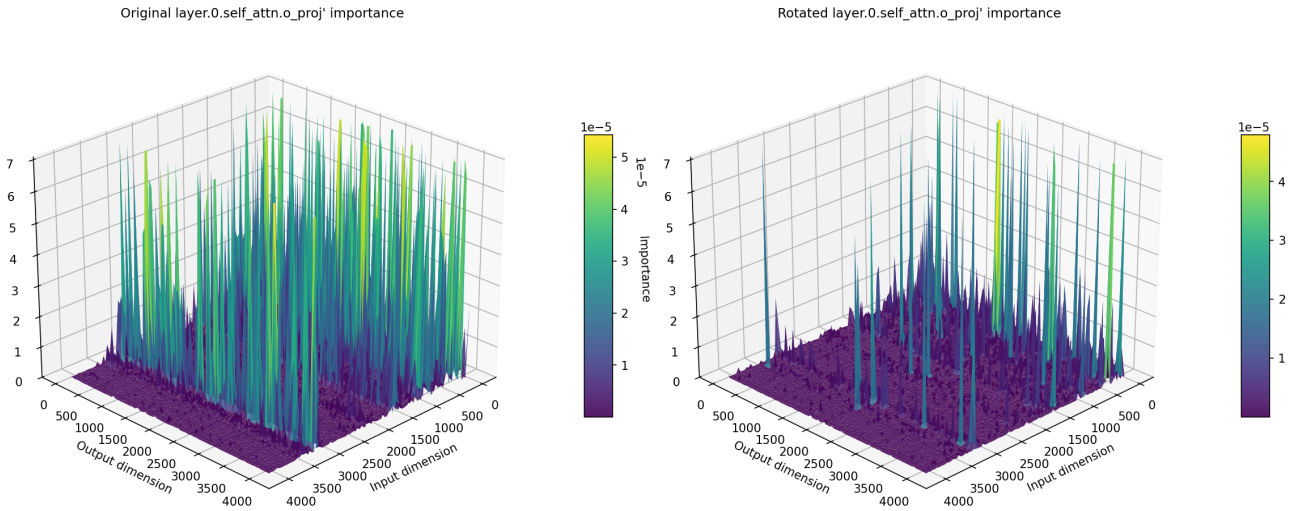

*图5.*LLaMA-3-8B第一层输出投影在正交旋转前后的重要性分布可视化。重要性分数采用SparseGPT（Frantar & Alistarh，2023）指标计算。

图5直观展示了LLaMA-3-8B模型第一层输出投影在应用我们学习到的正交旋转前后的SparseGPT重要性评分分布。旋转前，重要性值在权重矩阵中较为分散，形成了多个分布在不同输入/输出维度的中等高度峰值。旋转后，重要性分布明显集中：大部分条目坍缩为低重要性的“背景”，而少数权重则形成了更尖锐且占主导地位的峰值。

这种权重分布的集中特性与我们第一阶段设定的熵最小化目标高度契合。该目标明确要求归一化重要性分布具有更低的熵值，从而将参数权重集中到更少的参数上。从剪枝优化的角度来看，更集中的重要性分布能显著提升关键权重与非关键权重之间的区分度，使得单次剪枝更不容易误删那些功能必要但重要性中等的参数。因此，后续对合并后的旋转权重进行剪枝（例如通过SparseGPT算法）会变得更加稳健，特别是在高稀疏度场景下——此时剪枝预算迫使算法必须舍弃大量权重。

B. 大型模型的附加结果

方法	ARC-正性	零样本准确率（%）↑					困惑↓	
		ARC-e	HellaSwag	PIQA	WinoGrande	平均	维基文本2	C4
稠密	62.63	83.46	85.98	83.73	77.58	78.68	3.88	9.26
PrunerGPT（Shao 等人，2024）	62.46	84.76	84.37	82.54	78.85	78.59	4.95	9.89
DenoiseRotator（Gu 等人，2025）	60.58	83.08	85.05	82.92	77.98	77.92	4.76	9.76
EcoPrune-A	61.60	82.91	85.58	83.90	78.53	78.50	4.17	9.42
EcoPrune-B	61.35	83.50	85.62	83.35	78.53	78.47	4.18	9.44

*表7.*Qwen2.5-72B在50%稀疏度下的结果。我们报告了五个基准测试（ARC-c/ARC-e/HellaSwag/ PIQA /WinoGrande）上的零样本准确率，以及WikiText2和C4上的困惑度。↑/↓表示结果越高/越低越好。

表7和表。8在相同50%稀疏性设置下，进一步在更大规模的骨干网络上验证EcoPrune。总体而言，EcoPrune在保持（或提升）零样本准确率的同时，持续改善困惑度，表明我们的方法在7B–14B规模之外仍具有良好的扩展性。

机密审稿人副本。本手稿正在接受ICML 2026的双盲评审。未经授权的共享、再分发或披露均属禁止。
严禁。

严禁。

方法	零样本准确率（%）↑						困惑↓	
	ARC-正性	ARC-e	HellaSwag	PIQA	葡萄大	平均	维基文本2	C4
稠密	60.84	83.12	82.56	82.05	72.93	76.30	7.61	12.45
OWL（Yin 等人，2024）	22.70	25.08	79.69	49.51	71.43	49.68	8.73	13.71
DLP（Chen 等人，2025）	22.70	25.08	77.17	49.51	70.80	49.05	11.84	16.98
PrunerGPT（Shao 等人，2024）	59.90	80.05	79.55	80.20	72.22	74.38	8.73	13.48
DenoiseRotator（Gu 等人，2025）	58.70	79.76	81.10	81.34	72.77	74.73	8.17	13.09
EcoPrune-A	59.98	81.48	81.86	81.34	71.82	75.30	7.93	12.85
EcoPrune-B	61.26	83.00	81.78	80.69	72.06	75.76	7.93	12.92

*表8.*Qwen3-32B在50%稀疏度下的结果。我们报告了五个基准测试（ARC-c/ARC-e/HellaSwag/ PIQA /WinoGrande）上的零样本准确率，以及WikiText2和C4上的困惑度。↑/↓表示结果越高/越低越好。

Qwen2.5-72B.在Qwen2.5-72B（表7）上，EcoPrune在WikiText2和C4数据集上均取得最佳困惑度（EcoPrune-A为4.17/9.42，EcoPrune-B为4.18/9.44），优于PrunerGPT（4.95/9.89）和DenoiseRotator（4.76/9.76）。在平均零样本准确率方面，EcoPrune与最强基线模型竞争（78.50 vs. PrunerGPT的78.59）。

Qwen3-32B.在Qwen3-32B（表8）上，EcoPrune在平均准确率和困惑度上均持续优于先前方法。EcoPrune-B达到最高平均准确率（75.76），较PrunerGPT高出+1.38，较DenoiseRotator高出+1.03；而EcoPrune-A则呈现最低困惑度（7.93/12.85），优于DenoiseRotator（8.17/13.09）和PrunerGPT（8.73/13.48）。

这些结果表明，当模型规模增大时，EcoPrune仍保持稳健性，且在扩展至显著更大的模型规模时，重要性集中和基于熵的非线性稀疏分配的优势变得更加显著。

C. 不同单次修剪方法的附加消融研究

方法	零样本准确率（%）↑						困惑↓	
	ARC-正性	ARC-e	HellaSwag	PIQA	WinoGrande	平均	维基文本2	C4
稠密	52.73	77.78	79.19	80.96	72.93	72.72	6.14	9.44
幅度（Jaiswal 等人，2023）	35.92	58.46	59.33	72.2	62.98	57.78	30.39	36.20
+ EcoPrune	49.06	75.67	76.23	79.38	69.77	70.02	7.80	12.20
Wanda（Sun 等人，2023）	44.88	67.97	68.8	76.71	70.48	65.77	9.86	15.24
+ EcoPrune	50.43	75.84	76.59	79.27	72.61	70.95	7.08	11.04
SparseGPT (Frantar & Alistarh, 2023)	44.45	69.44	72.34	76.88	71.27	66.88	9.57	14.22
+ EcoPrune	50.43	77.06	77.47	80.36	73.01	71.67	6.79	10.54

*表9.*不同单次剪枝主干模型（Magnitude（Jaiswal 等人，2023）、Wanda（Sun 等人，2023）和SparseGPT（Frantar & Alistarh，2023））在50%稀疏度下对LLaMA-3-8B的消融实验。我们在五个基准集（ARC-c / ARC-e / HellaSwag / PIQA / WinoGrande）上报告了零样本准确率，并在WikiText2和C4上报告了困惑度。↑/↓表示较高/较低结果更优。

表9显示，在相同的50%稀疏预算下，EcoPrune能持续提升各类单次剪枝骨干模型的性能。对于幅度（Jaiswal等人，2023），添加EcoPrune后平均准确率从57.78提升至70.02，困惑度从30.39/36.20降至7.80/12.20（WikiText2/C4），表明重要性集中度和基于熵的非线性分配能显著缓解朴素剪枝准则的脆弱性。对于Wanda（Sun 等人，2023），EcoPrune将平均准确率从65.77提升至70.95，困惑度从9.86/15.24降至7.08/11.04。对于SparseGPT（Frantar & Alistarh，2023），EcoPrune进一步将平均准确率从66.88提升至71.67，困惑度从9.57/14.22降至6.79/10.54，表明EcoPrune基本不依赖主干网络，可与不同单次剪枝器结合以获得更强性能。

D. 目标稀疏度的全局极限

表10将全局目标稀疏度在LLaMA-3-8B上推至极端的80%，所有方法在此均出现严重性能下降。值得注意的是，OWL（Yin 等人，2024）、DLP（Chen 等人，2025）和PrunerGPT（Shao 等人，2024）

机密审稿人副本。本手稿正在接受ICML 2026的双盲评审。未经授权的共享、再分发或披露均属禁止。
严禁。

严禁。

方法	零样本准确率（%）↑						困惑↓	
	ARC-正性	ARC-e	HellaSwag	PIQA	葡萄大	平均	维基文本2	C4
稠密	52.73	77.78	79.19	80.96	72.93	72.72	6.14	9.44
OWL（Yin 等人，2024）	21.25	30.39	30.50	54.52	50.99	37.53	185.41	127.15
DLP（Chen 等人，2025）	22.61	31.44	31.05	56.53	51.46	38.62	188.25	123.32
PrunerGPT（Shao 等人，2024）	21.84	29.46	30.07	54.84	51.46	37.54	133.78	106.27
DenoiseRotator（Gu 等人，2025）	25.85	44.23	41.33	63.06	56.35	46.16	43.61	51.26
EcoPrune	29.61	51.39	48.06	67.41	58.80	51.05	36.11	48.08

*表10.*LLaMA-3-8B在80%稀疏度下的结果。我们在五个基准测试（ARC-c/ARC-e/HellaSwag/ PIQA /WinoGrande）上报告了零样本准确率，并在WikiText2和C4上报告了困惑度。↑/↓表示结果越高/越低越好。

在预算极度紧张的情况下，模型精度会大幅下降（平均值37.5-38.6），并表现出极高的困惑度（例如WikiText2/C4数据集上的困惑度>100），这表明其分配/剪枝行为变得不可靠。相比之下，EcoPrune展现出更强的鲁棒性，平均准确率达到51.05，困惑度为36.11/48.08，不仅比最强基线模型DenoiseRotator高出4.89个准确度单位，还成功将WikiText2/C4的困惑度降低了7.50/3.18。这些结果表明，当将全局稀疏度推向极限时，EcoPrune能提供更出色的鲁棒性表现。

□ 审稿人 CIny。本稿件正在由 inML 2q26 进行审稿。“分享”、“再分配”、“分配”

被严格禁止。